Specyfikacja funkcjonalna programu realizującego dekompresję plików skompresowanych algorytmem Huffmana

Autorzy: Adrian Chmiel, Mateusz Tyl

10.06.2023

Historia zmian dokumentu:

Autor:	Data:	Opis zmiany:	Wersja dokumentu
Adrian Chmiel	10.06.2023	Pierwsza wersja dokumentu	1.0
Adrian Chmiel	10.06.2023	Drobne poprawki	1.1
Adrian Chmiel	10.06.2023	Finalna wersja dokumentu	2.0

Cel projektu

Ten projekt jest kontynuacją projektu poprzedniego realizującego kompresję algorytmem Huffmana w języku C. Tym razem zadaniem było utworzenie programu w języku Java oferującego następujące funkcjonalności:

- Dekompresja plików pochodzących z wcześniej napisanego kompresora w języku C
- Sprawdzanie poprawności pliku poprzez m.in. sumę kontrolną
- Wizualizacja słownika poszczególnych znaków dla konkretnego pliku

Ze względu na ograniczoną czytelność drzewa obrazującego słownik dla wyższych poziomów kompresji, wizualizacja jest realizowana jedynie dla plików skompresowanych 8-bitowo.

Teoria

Algorytm Huffmana jest jednym z najprostszych i łatwych do zaimplementowania algorytmów wykorzystujących bezstratną kompresję danych. Jego działanie opiera się na tworzeniu zmiennodługościowych kodów binarnych dla poszczególnych znaków. Kody są generowane w oparciu o drzewo binarne tworzone na podstawie częstotliwości wystąpień znaków. Im częściej występuje dany znak, tym krótszy jest przypisany mu kod, a dla znaków występujących rzadziej kod jest dłuższy. W procesie kompresji, każdy znak w pliku zostaje

zamieniony na odpowiadający mu kod i zapisany w formie ciągu binarnego.

Na przykładzie pliku zawierającego tekst "alamakota" możemy zobaczyć, jak działa ten algorytm. Dla tego konkretnego przypadku zestaw kodów wyglądałby następująco:
Znak 'k' otrzymuje kod: 1111
Znak 'o' otrzymuje kod: 1110
Znak 'l' otrzymuje kod: 1101
Znak 'm' otrzymuje kod: 1100
Znak 't' otrzymuje kod: 101
Znak '\n' otrzymuje kod: 100
Znak 'a' otrzymuje kod: 0

Po zastosowaniu kompresji, plik zostaje zapisany jako ciąg skompresowanych danych:
011010110001111111010100

Następnie odczytując plik (zakładając, że jest to prawidłowy plik pochodzący z kompresora naszego autorstwa) należy zauważyć, że jest on podzielony na 3 sekcje:

- Nagłówek zawierający inicjały autorów, wszelkie flagi zawierające ustawienia kompresji oraz wynik sumy kontrolnej
- Zapis słownika dzięki któremu można dokonać późniejszej dekompresji
- Skompresowany zapis pliku

Na podstawie tych informacji możemy wywnioskować, że w dużym skrócie poprawna dekompresja pliku będzie przebiegać w sposób następujący:

1. 1. Weryfikacja poprawności pliku na podstawie informacji z nagłówka
2. 2. Odczytanie słownika dla danego pliku
3. 3. Porównywanie kodów napotkanych przy analizie pliku z tymi, które znajdują się w słowniku
4. 4. Zapisywanie do pliku wyjściowego odpowiedniego symbolu, jeżeli kody się pokryją

Dane wejściowe

Program wymaga przekazania dowolnego pliku, który pochodzi z kompresora w języku C napisanego przez nas w ramach poprzedniego projektu. W przypadku podania innego pliku dekompresja się nie powiedzie, a program zwróci jeden z kodów błędu.

Uruchamianie programu

Program może być uruchomiony w jednym z dwóch trybów:

- `wsadowy` - wymagane są dwa parametry tj. nazwa pliku, który chcemy zdekompresować oraz nazwa pliku wyjściowego
  Lista parametrów opcjonalnych:
  - `-h` - wyświetl pomoc do programu
  - `-c` - zaszyfruj wynik działania programu
  - `-d` - wymuś dekompresję
- `graficzny` - wyświetla graficzne okienko umożliwiające wybór pliku oraz pożądanych opcji dekompresji pliku, a następnie w przypadku plików skompresowanych 8-bitowo wyświetlenie wizualizacji słownika

Uwaga! Przy uruchamianiu dekompresora w trybie wsadowym wizualizacja słownika nie zostanie wyświetlona.

Uruchamianie programu przez IntelliJ IDEA

Niezwykle pomocnym narzędziem przy realizacji tego projektu był definitywnie IntelliJ IDEA od JetBrains, który jest dostępny za darmo. W celu uruchomienia dekompresora w tym środowisku programistycznym bez przeszkód, po pobraniu całego projektu najlepiej będzie najpierw ustawić katalog DekompresorGUI\src\main\java jako Source Root, a następnie katalog główny zawierający całość projektu jako kolejny Source Root. Po wykonaniu tych ustawień możemy sobie przygotować dwie konfiguracje takie jak widoczne na poniższych zrzutach ekranu:

- tryb graficzny

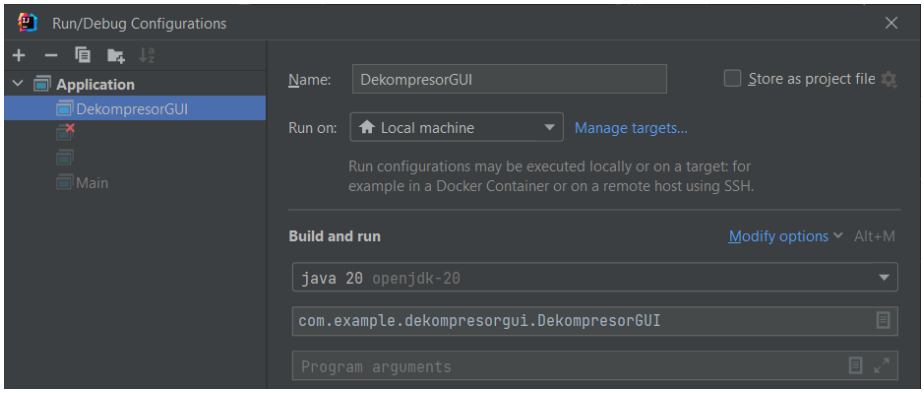

- tryb wsadowy

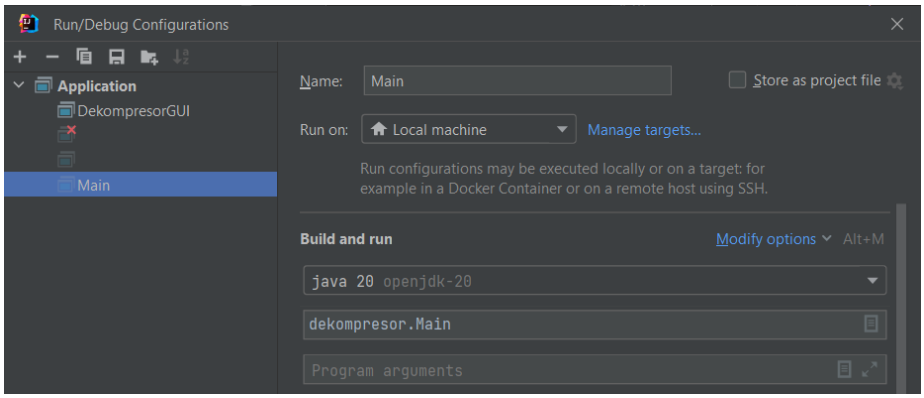

Ostatnim krokiem będzie dodanie biblioteki JavaFX do struktury projektu, co możemy zrobić poprzez przejście w File > Project Structure > Libraries. Następnie klikamy na '+' i odnajdujemy ścieżkę z JavaFX, który powinien być dołączony razem z projektem. Koniecznie wybieramy folder **lib**. Po wykonaniu tego zadania całość powinna się prezentować mniej więcej tak, jak na zrzucie poniżej:

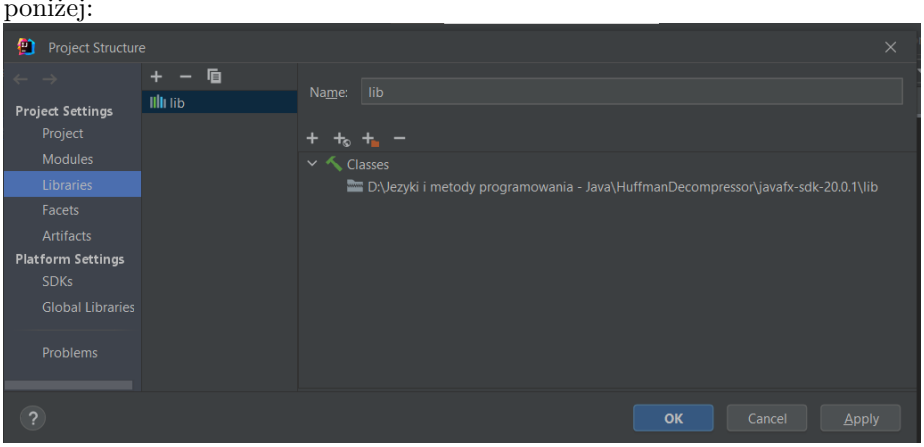

Przykłady wywołania programu

Przedstawione zostały jedynie przykłady dla trybu wsadowego przy założeniu, że znajdujemy się w głównym katalogu projektu (w innym przypadku wymagane może być podanie innej ścieżki do pliku *Dekompresor.jar*)

- **java -jar Dekompresor.jar test/8-bit/easy-text-test output**
  Program wczyta plik o nazwie easy-text-test z katalogu test/8-bit i go zdekompresuje
- **java -jar Dekompresor.jar test/8-bit/cipher8 output -c**

Program wczyta plik o nazwie cipher8 z katalogu test/8-bit i zdekompresuje go do pliku output z włączonym szyfrowaniem używając domyślnego kodu "Politechnika_Warszawska"

- **java -jar Dekompresor.jar -h**
  Zostanie wyświetlona pomoc do programu

W przypadku trybu graficznego GUI jest bardzo przejrzyste i intuicyjne, jak widać na załączonym niżej zdjęciu oraz jego obsługa nie powinna sprawiać najmniejszych problemów. Składa się ono z następujących elementów:

- przycisk do wyboru pliku, który chcemy zdekompresować
- pole tekstowe do wpisania względnej ścieżki pliku wyjściowego
- pola wyboru, w których możemy dostosować ustawienia
- pole tekstowe do wpisania szyfru inny niż domyślny *(dostępne jedynie po zaznaczeniu opcji szyfrowania)*
- przycisk ***Dekompresuj*** uruchamiający faktyczną część programu
- pasek ładowania przedstawiający obecny stan dekompresji

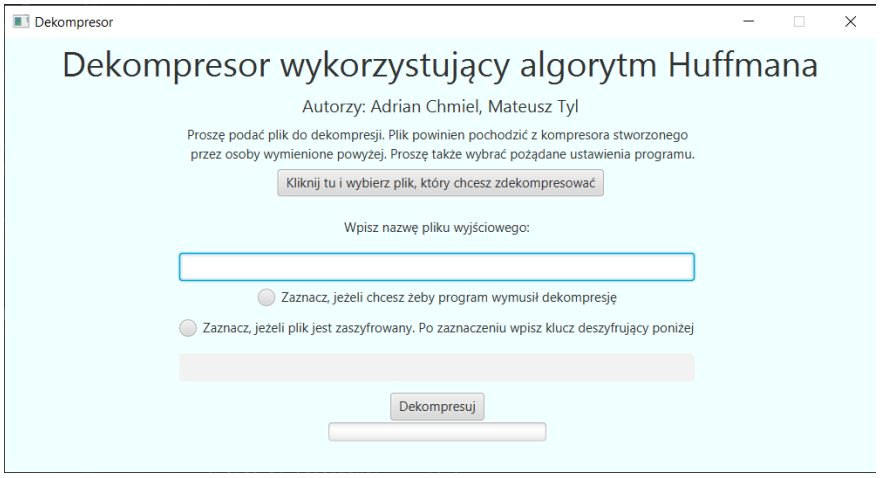

Wizualizacja słownika

Wizualizacja słownika w postaci drzewa wyświetla się zaraz po ukończeniu dekompresji *(lecz jedynie, gdy plik wejściowy został skompresowany 8-bitowo)*. Domyślnie jest mocno zbliżona do korzenia i zdecydowana większość drzewa może być niewidoczna na pierwszy rzut oka, dlatego zaimplementowana została możliwość przeciągania po okienku przy pomocy lewego klawisza myszy oraz przybliżania i oddalania widoku przy pomocy rolki.
Wizualizacja składa się z węzłów tj. kwadratów połączonych w odpowiedni sposób przy pomocy linii. Węzły zawierać mogą poszczególne dane:

- kod odpowiadający danemu węzłowi znajdujący się bezpośrednio nad nim
- symbol odpowiadający danemu kodowi *(jedynie, gdy jest to liść)*

Przykładowe zrzuty ekranu wizualizacji zawarte są poniżej:

- Maksymalnie oddalony widok wizualizacji

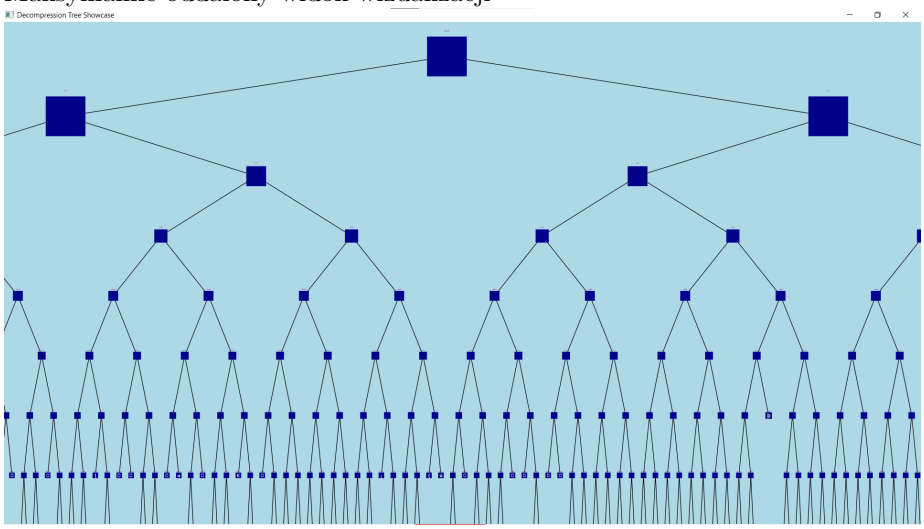

- Zbliżenie na liście przedstawiające możliwość odczytania symboli i kodów

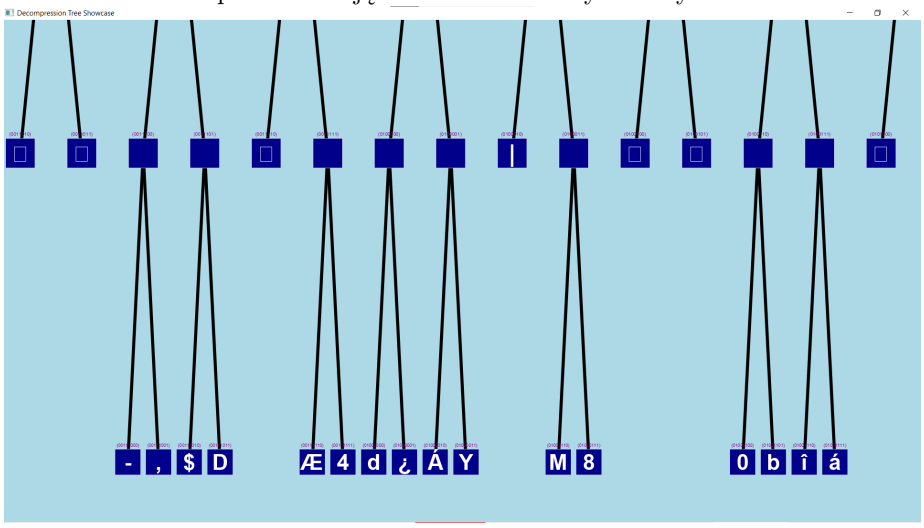

- Przykładowy fragment wizualizacji dla prostszego pliku

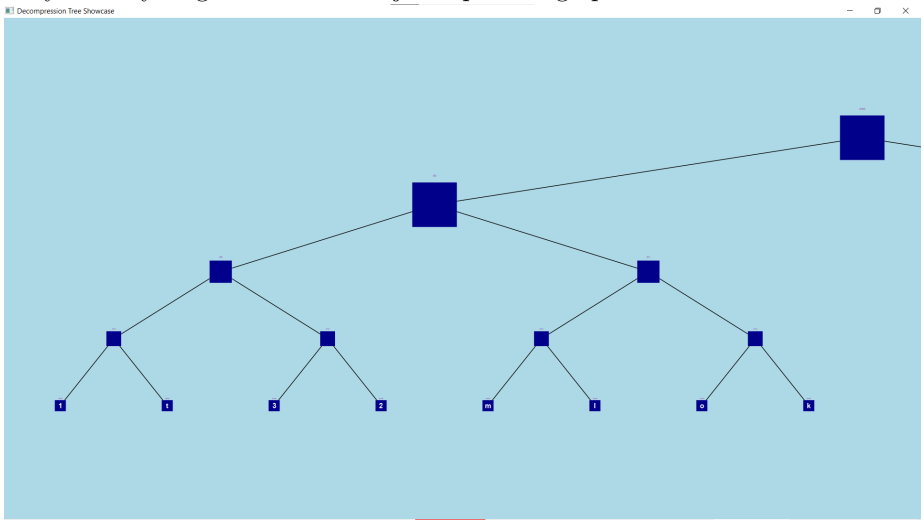

Struktura pliku wejściowego

Pierwsze cztery bajty pliku wyjściowego zarezerwowane są na nagłówek.
Pierwsze dwa bajty nagłówka to pierwsze litery nazwisk autorów - CT.
Kolejny bajt to maska, z której można odczytać szczegółowe informacje o pliku.
Ostatnim bajtem nagłówka jest wynik wyliczonej sumy kontrolnej.
Następnie pojawia się słownik, a na końcu znajdują się kolejno po sobie skompresowane dane w postaci kodów Huffmana o zmiennej długości.
W przypadku, gdy po zapisaniu wszystkich danych ilość bitów w ostatnim bajcie jest niekompletna, zostanie wykonane dopełnienie zerami. Jeżeli użytkownik wybierze zarówno brak kompresji, jak i brak szyfrowania, to otrzymuje on dokładnie ten sam plik, jak ten podany jako wejściowy.

Struktura maski w nagłówku pliku

Szablon bitowy: 0bKKSZCEEE

- K - sposób kompresji: 00 - brak, 01 - 8-bit, 10 - 12-bit, 11 - 16-bit
- S - szyfrowanie: 0 - nie, 1 - tak
- Z - zapisanie informacji, czy konieczne będzie usunięcie nadmiarowego znaku \0 z końca pliku podczas dekompresji
- C - dodatkowe sprawdzenie, czy ten plik jest skompresowany: 0 - nie, 1 - tak
- E - ilość niezapisanych bitów kończących (tj. dopełniających ostatni bajt) zapisana binarnie

Słownik

Kod Huffmana każdego znaku wraz z odpowiadającym mu znakiem można odczytać ze słownika, który znajduje się od razu po nagłówku. Do odczytania słownika będzie potrzebny odpowiedni algorytm.
Algorytm prezentuje się następująco:
Tworzymy pomocnicze drzewo binarne. Rozpoczynamy analizę bitów składających się na słownik. Znajdujemy się w korzeniu drzewa. W zależności na co napotkamy analizując kolejne bity (analizujemy kolejno po dwa) robimy to co następuje:

- 00 - przechodzimy po drzewie w dół do lewego syna, jeżeli ten jest nieodwiedzony, w przeciwnym razie do prawego syna
- 01 - to samo co 00, ale po tym przejściu znajdziemy się w liściu - wtedy otrzymujemy kod znaku w całości, kolejne 8/12/16 (w zależności od poziomu kompresji) bitów to znak, którego kod otrzymaliśmy.
- 10 - wycofanie się do ojca
- 11 - koniec słownika

W przypadku napotkania na 01 możemy z drzewa odczytać cały kod Huffmana dla konkretnego znaku. Kod czytamy od liścia w stronę korzenia. Z kolejnych 8/12/16 (w zależności od poziomu kompresji) bitów możemy odczytać kodowany znak.
Uwaga - zawsze po odczytaniu znaku (tzn. odczytaniu 8/12/16 bitów) w drzewie należy wykonać cofnięcie z aktualnej pozycji do ojca!

Przykład (dla kompresji 8 bitowej):
Nasz przykładowy słownik:

`0101100010000001011001000101100001100101`

Analizujemy pierwsze dwa bity

`01`0110001000000101100100010110000110010 1

Zatem przechodzimy do lewego syna. Znajdujemy się w liściu, co oznacza że właśnie otrzymaliśmy znak. Odczytujemy z drzewa kod Huffmana dla aktualnego znaku. W tym przypadku jest to 0. Lewą gałąź w drzewie oznaczamy zerem, prawą jedynką. Odczytujemy kolejne 8 bitów. Te bity to znak, którego kod Huffmana właśnie otrzymaliśmy.

`01`01100010000001011001000101100001100101

Otrzymaliśmy zatem pierwszy znak i odpowiadający mu kod Huffmana.
Znak w postaci binarnej: 01100010, w postaci dziesiętnej: 98
Odpowiadający mu kod Huffmana to: 0
Dalej postępujemy tak samo, pamiętając, że jeżeli napotkamy na `11` to słownik

zostaje zakończony. W przypadku braku kompresji słownik nie jest wcale zapisywany.

Szyfrowanie

Szyfrowanie pliku odbywa się za pomocą *Szyfrowania Vigenère'a*. Domyślnie kluczem szyfrowania jest: `Politechnika_Warszawska`

W celu zmiany klucza szyfrowania możemy skorzystać z argumentu `-c "klucz"` np.
`-c "Huffman"` ustawi klucz szyfrowania na `Huffman`

Ten rodzaj szyfrowania polega na przesuwaniu kolejnych zapisywanych znaków o wartości ASCII kolejnych znaków znajdujących się w kluczu szyfrowania. W momencie, gdy podczas szyfrowania znajdziemy się na końcu klucza, należy po prostu wrócić na jego początek i kontynuować szyfrowanie przechodząc po nim kolejny raz.
Szyfrowaniu podlega słownik oraz skompresowany tekst, a więc wszystko oprócz nagłówka w postaci czterech pierwszych bajtów pliku.

Struktura pliku wyjściowego

Plikiem wyjściowym jest po prostu zdekompresowany plik, który jest identyczny z plikiem wcześniej skompresowanym przy użyciu kompresora naszego autorstwa w języku C.

Komunikaty błędów

1. Błąd podczas wczytywania pliku wejściowego: `Input file could not be opened!`
2. Plik wejściowy jest pusty: `Input file is empty!`
3. Błąd podczas wczytywania pliku wyjściowego: `Output file could not be opened!`
4. Pominięcie niezindentyfikowanych argumentów: `Unknown argument! (ignoring...)`
5. Podany szyfr nie umożliwia pomyślnej dekompresji: `Decompression encryption failure!`
6. Napotkano błąd przy zapisie pliku wyjściowego: `Output file error!`
7. Napotkano błąd przy zapisie pliku pomocniczego do GUI: `Data file error!`

8. Napotkano błąd przy zapisie pliku realizującego wizualizację słownika: `Tree file error!`

Zwracane wartości

Program po zakończeniu pracy zwraca wartość typu całkowitego, która może być użyteczna w przypadku identyfikacji różnego rodzaju niepowodzeń:

- 0 - Program zakończył się pomyślnie
- 1 - Podano za mało argumentów
- 2 - Błąd przy operacjach na pliku wejściowym
- 3 - Błąd przy operacjach na pliku wyjściowym
- 4 - Pusty plik wejściowy
- 5 - Podano plik, który nie może zostać zdekompresowany
- 6 - Podano nieprawidłowy szyfr przy dekompresji

Należy jednak pamiętać, że podanie nieprawidłowego szyfru może się również zakończyć powodzeniem, lecz uzyskany plik wynikowy nie będzie zgodny z oryginałem tj. plikiem przed kompresją (wizualizacja słownika również nie ukaże drzewa, które jest prawidłowe dla danego pliku).